


Compañero de Lectura: un agente RAG que sabe por dónde vas

Giano Montaña, Brayan Avila, Aaron Arana, Rodrigo Chang, Erick Olivares



El problema

Según la Evaluación Nacional de Logros de Aprendizaje de Estudiantes de 2023, solo el 18,4 % de los estudiantes de segundo de secundaria alcanzó el nivel satisfactorio en lectura.

Afecta a estudiantes de secundaria

Con dificultades de comprensión lectora, y de rebote a docentes y familias

Leen sin apoyo fuera del aula

La duda surge a las 9 de la noche, el profesor responde al día siguiente

Sin nadie que verifique

El estudiante no sabe si entendió o si solo pasó los ojos por la página

Un ChatGPT con el PDF pegado no sirve

No sabe por dónde va y le revienta el final del libro

Consecuencia

Abandonan la lectura, o la "resuelven" con un resumen de internet



Nuestra solución

Un compañero de lectura que acompaña la obra y sabe exactamente hasta dónde has leído.

Responde dudas

Sobre la obra, citando los pasajes exactos en los que se apoya (RAG)

Te pregunta a ti

En puntos marcados del texto, y evalúa tu respuesta con feedback personalizado

Ilustra

El pasaje que estás leyendo, para anclar la escena

Identifica personajes y lugares por fragmento

y los muestra progresivamente según el avance del estudiante.



Todo ello respetando el progreso de lectura y sin recuperar fragmentos posteriores.

Las banderas: aquí el chat te pregunta a ti

El estudiante no solo consulta: también se detiene a reflexionar sobre lo que acaba de leer.

1 Puntos marcados dentro de la obra

Donde el compañero lanza una pregunta de comprensión

2 392 checkpoints de comprensión integrados en el corpus

No improvisadas por el modelo

3 Son de comprensión y de opinión

Piden interpretar y aventurar hipótesis, no repetir el texto

4 El feedback es formativo, nunca una nota

Reconoce lo valioso de su idea y tira de ese hilo

5 Objetivo: favorecer la comprensión y la retención

Obligan a detenerse, verbalizar y consolidar antes de seguir

The screenshot shows a chat interface with a header bar containing navigation links: "Inicio", "Historia", "Preguntas", "Respuestas", "Fuentes", and "Ayuda". Below the header, there's a section titled "Elementos de la historia" with a list of items: "Golfo", "Santiago", "Terraza", "Habana", "Norte", "Recuerdo", "Gracias", and "Mosquitos". Each item has a small icon. Below this list, there's a question: "¿Cómo se describe al viejo Santiago al inicio de la historia?". A blue button with the text "como un viejo cansado" is visible. Below the question, there's a text box with the following content: "Tu respuesta capta una idea general válida, porque al inicio Santiago sí aparece como un hombre envejecido y agotado. Sin embargo, no alcanza la evidencia en los fragmentos disponibles para confirmar esa descripción con precisión, así que conviene afinarla con más apoyo textual. Relee el inicio de la obra y revisa las palabras exactas con que se presenta a Santiago." Below this text box, there's another question: "Pregunta de comprensión: ¿Cómo es la relación entre Santiago y Manolín?". A blue button with the text "Es como su hijo, pero lo trata seriamente, como una figura paterna fuerte" is visible. Below this button, there's another text box with the following content: "Vas bien al ver que entre Santiago y Manolín hay un vínculo casi de padre e hijo, porque se nota cariño y confianza en cómo hablan y en que el muchacho quiere volver con él. También aciertas al notar que Santiago no lo mima: lo trata con firmeza y le enseña a respetar su camino, como cuando le dice que siga con el bote que tiene buena suerte. Esa mezcla de afecto y disciplina hace que su relación se sienta muy cercana y muy seria a la vez." Below this text box, there's a section titled "Fuentes" with a list of items: "1". Below this section, there's a text input field with the placeholder text "Escribe tu pregunta..." and a button labeled "Enviar".

Arquitectura

Un router pequeño clasifica la intención; herramientas especializadas hacen el trabajo.

01

Modelo ligero clasificador

Un **modelo ligero (Llama 3.1 8B, temp. 0)** clasifica cada mensaje en 5 intenciones

02

Modelo grande generador

Un **modelo grande** genera el contenido: respuestas y retroalimentación

03

Cinco herramientas

QA-RAG, evaluación, ilustración, resumen y grafo de personajes

04

Atajo para preguntas pendientes

Si el estudiante tiene una pregunta pendiente, **se salta el router** y va directo a evaluación

05

Patrón de referencia

Patrón router + tools, siguiendo ReAct, ToolLLM y RouteLLM

El motor: RAG sobre texto narrativo

Un pipeline de recuperación diseñado para novelas, no para documentos técnicos.

Chunking consciente de bloques narrativos

Agrupa bloques completos, ~410 tokens de media, cero truncados

Embeddings multilingual-e5-base

Sobre **ChromaDB**

Corpus final

8 obras del Plan Lector, 2.353 chunks, 392 preguntas, 12.593 bloques

Citas con offsets de carácter

Cada respuesta devuelve **citas con offsets de carácter**: el estudiante puede ir al pasaje

Fase 1 fue un estudio comparativo de RAG; hoy es el motor de una aplicación desplegada

Bitácora

Cinco personas, cuatro agentes de terminal, y una bitácora en el repo como único protocolo.

| - 5-14 de julio. Cada cambio en una pieza compartida deja escrito qué rompió y qué le toca al siguiente

| - 7 jul — ¿qué es "hasta dónde ha leído"? Se pensó originalmente en secciones, Chang en chunks. Todo el anti-spoiler colgaba de esa unidad

| - 8 jul — Backend consolidado listo para frontend con Erick

| - 13 jul — el medidor no veía medio libro. Bloques huérfanos → progreso mal medido → el anti-spoiler bloqueaba pasajes ya leídos

| - 14 jul — las imágenes "alucinadas". El planificador caído en silencio enviaba la prosa de Kafka como prompt; el modelo la dibujaba de pie de foto

| - La lección: no eran alucinaciones del modelo, eran contratos mal escritos entre nuestras piezas

- Lo de la conexión no es el comando: es que el backend no está levantado (conn... arrancar uvicorn primero. Pero antes, pruebo la key nueva.

Ran 1 shell command

- La key nueva funciona. Ahora aplico exactamente lo que querías: content de pag... de NVIDIA. Para eso era el provider por rol.

Ran 1 shell command

- Ahora verifico que los tres roles aterrizan en el proveedor correcto y que ca...

Ran 1 shell command

- Los tres roles aterrizan donde deben y los tres responden. Reejecuto la verif...

Ran 1 shell command

- Todo verde, y con la config que querías: se paga solo el content.

rol	provider	modelo
router	NVIDIA	meta/llama-3.1-8b-instruct (gratis)
visual planner	NVIDIA	meta/llama-3.1-8b-instruct (gratis)
content	OpenAI	gpt-5.4-mini (de pago)

(La línea scene_planner falló: 404 de arriba es del tercer test a propósito - ahora revienta en vez de dibujar español.)

Te saco el comando exacto para levantar el backend.

Ran 1 shell command

Jump to bottom (ctrl+F) |

Anti-spoiler: la pieza que nos hace distintos

El sistema conoce tu posición en la obra y se prohíbe a sí mismo mirar más allá.

La barrera estructural

El avance de lectura se calcula en el frontend y se expresa como un **índice monótono de chunks**

La barrera se aplica **en la recuperación**: nunca se recupera un fragmento por encima de tu progreso

Por qué es diferente

No es un clasificador que "detecta" spoilers: es una restricción estructural, imposible de saltar

Adaptación original a educación de la investigación en detección de spoilers (EMNLP 2023)

Lo probamos con estudiantes reales

n = 6 sesiones grabadas, con estudiantes de secundaria, sobre su propia lectura asignada.

6/6

Dijeron que lo usarían

Sin que se les preguntara, que lo usarían para su Plan Lector

5/6

Completaron consultas libres

5 de 6 completaron una pregunta de comprensión con feedback

0

Reportaron confusión

Ninguno reportó la experiencia como confusa; uno destacó las preguntas como lo más útil

Hallazgo positivo

Repetir "aquí no hay respuesta correcta ni incorrecta" **reducía visiblemente su bloqueo**

Hallazgo negativo

Ninguno encontró solo el disparador de las preguntas → nos falta onboarding

[illegible]

Qué falló y qué sigue

Las pruebas nos dieron una lista de tareas que no nos habríamos dado nosotros.

Lo que ya arreglamos

- **Ilustración:** falló en casi todos los intentos. Causa raíz ya localizada; queda pulir fiabilidad
- **Vocabulario:** "¿qué significa esta palabra?" no se responde de forma fiable. Hay que darle su propia herramienta

Lo que sigue

- **Resumen y grafo de personajes:** siguen sin implementar, y el resumen lo pidió un estudiante
- **Móvil y onboarding:** dos de seis entraron por celular y sufrieron; nadie encontró las preguntas solo
- **Validar las 392 preguntas con docentes,** y mejorar el enrutado a mejores APIs y modelos